

서울교육 데이터 분석·활용 아이디어 공모전 데이터 분석 기획보고서(일반부)

작품명	YOLOv5 · MediaPipe · GRU 기반 학교폭력 자동 탐지 모델	
주제 분야	<input type="checkbox"/> 교육과정·수업평가 <input type="checkbox"/> 고교다양화 <input type="checkbox"/> 체육·예술교육 <input type="checkbox"/> 유아교육 <input type="checkbox"/> 기회의평등 <input type="checkbox"/> 민주시민·인권교육 <input type="checkbox"/> 학교업무경감·교원정책 <input type="checkbox"/> 서울형혁신학교 및 미래교육지구(구 혁신교육지구) <input checked="" type="checkbox"/> 안전 <input type="checkbox"/> 서울교육공동체 <input type="checkbox"/> 교육공간 변화	
활용 데이터 목록		
제공 기관(사이트)명	데이터명	출처(URL)
AI-Hub	실내(편의점, 매장) 사람 이상행동 데이터	https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&dataSetSn=71550
서울 열린데이터 광장	서울시 학교 총괄 통계	https://data.seoul.go.kr/dataList/199/S/2/data.setView.do#
서울시 교육청	CCTV 설치 현황	https://buseo.sen.go.kr/buseo/bu15/user/bbs/BD_selectBbs.do?q_rowPerPage=10&q_currPage=1&q_sortName=&q_sortOrder=&q_searchKeyTy2=1005&q_searchStartDt=&q_searchEndDt=&q_bbsSn=1333&q_bbsDocNo=20220927174206000&q_searchKeyTy=ttl_1002&q_searchVal=&
서울시 교육청	유·초·중·고·특수·각종학교 학급편성 결과	https://enews.sen.go.kr/news/view.do?bbsSn=183875&step1=3&step2=1

-제6회 서울교육 데이터 분석·활용 아이디어 공모전-

YOLOv5 · MediaPipe · GRU 기반

학교폭력 자동 탐지 모델

Team: 완전안전

구동현*, 김동준*, 김승현*, 정민우*, 한동민*

* 동국대학교 산업시스템공학과

목 차

요약	2
I. 배경 및 목적	2
II. 배경이론	4
II-1. YOLOv5	4
II-2. MediaPipe	4
II-3. LSTM	4
II-4. GRU	5
III. 분석내용	5
III-1. 데이터 수집 및 전처리	5
III-2. 모델 학습	6
III-3. 분석 결과 및 학습	6
III-4. 다른 모델과의 성능 비교	7
IV. 활용 방안 및 기대 효과	8
V. 참고문헌 및 활용 데이터	9


요 약

청소년기 학생들에게 심각한 악영향을 미치고 피해자들이 성인이 된 이후에도 큰 고통을 남기는 학교폭력은 우리 사회의 큰 문제이다. 그 심각성에 대한 우리 사회의 관심은 나날이 커지고 있다. 본 프로젝트는 학교폭력을 감소시키고자 폭력행위를 실시간으로 탐지할 수 있는 모델을 개발해 CCTV에 적용하고자 한다. 이를 위해서 YOLOv5 · MediaPipe를 활용해 CCTV 영상 속 객체 탐지 및 객체의 관절 좌표를 도출하였다. 이후 GRU 기반 관절 좌표의 시계열 분석을 통해 영상 속 폭력행위를 탐지하는 모델을 제안한다.

I. 배경 및 목적

학교 폭력은 피해자에게 심리적, 육체적 고통을 주며 학교 내부의 안전을 위협한다. 또한 학교폭력 피해자에게 학업 중단, 학업 집중도 저하부터 시작해 우울증을 비롯한 정신적 질병 및 극단적 선택까지 이르게 하는 부정적인 결과를 초래할 수 있다. 나아가 성인이 된 후에도 정신질환, 약물중독 및 사회부적응을 일으키는 등 생애 전반에 걸쳐 악영향을 미치게 된다.

학교폭력 피해 학생의 비율을 나타내는 학교폭력 피해율은 2013년부터 2017년까지는 감소했으나 코로나 영향을 받은 일부 시기를 제외하고 다시 증가하는 추이를 보여준다. (그림1)



<그림1 학교폭력 피해율, 2013-2022>¹

교육부에서는 학교폭력을 근절시키기 위해 학교폭력 근절 종합대책을 마련하며 많은 노력을 기울이고 있다. 교육부와 한국대학교육협의회가 2023년 발표한 '2026학년도 대학 입학 전형 기본 사항'에 따르면 2026학년도 입시부터 모든 대학, 모든 전형에서 학교폭력 관련 기록을 의무적으로 반영한다.² 서울시 교육청에서 학생 안전 관리에 관한 예산도 지속해서 늘고 있는 추세이다. 제4차 학교폭력 예방 및 대책 5


¹ 1) 피해율=(피해 응답 인원 수÷참여자 수)×100

2) 2020년의 경우, 코로나19로 인해 전수조사로 1회만 조사됨(고3 제외). 2020년을 제외한 모든 연도는 1차 조사 결과임
통계청 통계개발원, 한국의사회동향2023

² 한국대학교육협의회.(2023).2026학년도 대입입학전형시행계획 발표

개년 기본계획을 보면, 교육부는 학교 폭력 예방 대책의 일환으로 학교 내 안전 사각지대에 CCTV 추가 설치와 화질 개선 등의 정책을 추진하고 있다. 2024년 서울특별시 교육비 특별회계 예산안에서 학생 안전관리 예산 중 학교 CCTV 설치지원 등으로 작년 대비 10.6억 원 증액했고, 24년 1차 추경예산에서도 학교 CCTV 설치지원 명목으로 16.8억 원 증액했다³. 이처럼 정책에 따라 CCTV 관련 예산과 설치 대수는 지속적으로 증가하고 있으나 학교폭력 감소에는 큰 영향을 미치지 못하고 있는 실정이다.

2016, 2017, 2018, 2022, 2023년 5개년⁴의 서울 시내 초중고 학생 만 명당 교내 CCTV 개수와 학교폭력 피해 학생 수를 비교한 그래프(그림2)를 보면 CCTV 개수는 꾸준히 증가하지만 피해 학생 수는 오히려 소폭 늘어난 경향을 보인다.



<그림2 학폭 피해 학생, CCTV 수 (학생 만명당)>

현재 서울시 CCTV 수에 비해 통합 관제센터의 관리 인력은 부족⁵하다. 서울특별시 25개 자치구 통합관제센터 직원 1인당 관제하는 CCTV 수가 평균 958개에 달하는 것으로 나타난다. 이는 행정안전부 기준 적정 수준(1인 당 50대)을 무려 19배 이상 초과한 수치이다. 즉, 기존 CCTV는 위험한 상황에 대한 실시간 감지, 선제 조치는 불가능한 상황이며 그저 사후 증거 수집용으로만 이용되고 있다. 따라서 학교폭력 자동 탐지 모델을 적용한 지능형 CCTV를 통해 학교폭력 상황에 즉각 대응할 필요가 있다.

교육부에서 발표한 '2023년 1차 학교폭력 실태조사 결과'를 보면 학교폭력의 피해유형은 언어폭력(37.1%), 신체폭력(17.3%), 집단 따돌림(15.1%)순으로 신체폭력이 2순위로 매우 높은 비율을 차지하고 있다. 학교폭력 피해 장소 조사 결과, 학교안이 68.8%로 대부분을 차지하고 그 중 교실을 제외한 복도, 계단, 운동장, 강당 등의 장소가 31.3%를 차지한다. ⁶

따라서 이와 같은 장소에 있는 CCTV 영상을 실시간으로 분석하고 폭력을 탐지하는 모델을 적용해 학교 내 안전 사각지대에서의 학교폭력을 방지하고자 한다.

³ 2024년도 서울특별시교육비특별회계 예산안

2024년도 제1회 서울특별시교육비특별회계 추가경정예산(안)

⁴ 2019,2020,2021년 서울시 학교 내 CCTV 현황 데이터 부재

⁵ 2023국회 교육위원회 국정감사

"서울 CCTV 관제센터 1인당 평균 958대 담당...적정수준 19배", 연합뉴스, 고은지

⁶ 2023년 1차 학교폭력 실태조사, 교육부

II. 배경이론

II-1. YOLOv5

딥러닝 분야에서 YOLO(You Only Look Once)는 실시간 객체 감지 작업에 사용되는 대표적인 신경망 중 하나이다. 높은 정확도와 빠른 속도로 다양한 객체를 실시간으로 감지하는 데 뛰어난 성능을 보인다. 객체 감지는 이미지 내에서 객체의 위치와 종류를 식별하는 작업으로, YOLOv5는 이러한 작업을 한 번의 스캔으로 객체의 특징과 경계선을 계산한다⁷.


II-2. MediaPipe

MediaPipe는 BlazePose 연구를 기반으로 RGB 비디오 프레임에서 33개의 관절을 추론하는 신체 자세 추적을 위한 머신러닝 솔루션이다. BlazePose는 lightweight CNN 아키텍처를 사용하여 높은 성능과 효율성을 제공한다. MediaPipe는 신체 자세를 추적하는 데 필요한 계산량을 줄여 실시간 추적을 가능하게 한다.

자세 추적은 두 단계의 머신러닝 파이프라인으로 구성된다. 첫 번째 단계는 자세 검출기로, 비디오 프레임 내에서 자세 ROI(관심 영역)를 찾는다. 이 단계에서는 전체 프레임을 분석하여 신체가 위치한 영역을 식별한다. 두 번째 단계는 자세 추적

기로, 검출된 ROI에서 33개의 관절을 예측한다(그림3).

MediaPipe는 신체 자세 추적을 통해 다양한 분야에서 효율적이고 정확한 분석을 제공할 수 있는 강력한 도구이다.⁸



<그림3 MediaPipe 관절점 추출 예시>⁹

II-3. LSTM

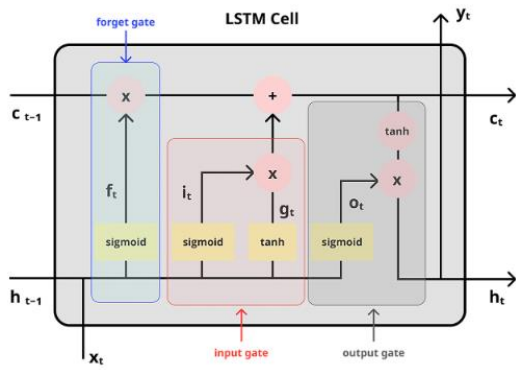
LSTM은 시계열 데이터를 처리하기 위해 설계된 순환 신경망(RNN)의 일종이다. LSTM은 RNN에서 gate를 추가하여 cell state의 구조를 제안한 기법이다. 과거 정보를 모두 반영하는 대신 forget gate와 input gate를 이용해 정보를 선별한다. 즉, 필요한 정보는 많이 채택하고 불필요한 정보는 버리는 방식을 취함으로써 장기 의존성 문제를 해결한 방식이다.

⁷ 심태웅, 김도윤, 최종인, & 박광영. YOLOv5 기반의 폐기물 자동인식 시스템 설계.

윤영웅, 정형섭, & 이원진. (2022). 고해상도 원격탐사 영상을 이용한 YOLOv5 기반 굴뚝 탐지. 대한원격탐사학회지, 38(6), 1677-1689.

⁸ Kwon, Y., & Kim, D. (2022). Real-Time workout posture correction using OpenCV and MediaPipe. 한국정보기술학회논문지, 20(1), 199-208.

⁹ Chen, K. Y., Shin, J., Hasan, M. A. M., Liaw, J. J., Yuichi, O., & Tomioka, Y. (2022). Fitness movement types and completeness detection using a transfer-learning-based deep neural network. Sensors, 22(15), 5700.



<그림4 LSTM 구조>¹⁰

II-4. GRU

GRU(Gated Recurrent Unit)는 2014년 발표된 모델¹¹로 LSTM을 단순화한 구조이므로 상대적으로 적은 파라미터 수를 가지기 때문에 학습 속도가 더 빠르다.

GRU를 구성하는 Reset gate는 직전 시점의 은닉층의 정보를 활용하는 정도를 결정하며, Update gate는 과거와 현재 시점의 정보를 각각 갱신하는 비율을 결정¹²한다.

III. 분석내용

III-1. 데이터 수집 및 전처리

폭력행동 감지 모델에 사용할 데이터는 AI-Hub의 '실내(편의점, 매장) 사람 이상행동 데이터' 공공데이터를 활용했다.

해당 데이터셋은 8가지의 이상행동(전도, 파손, 방화, 흡연, 유기, 절도, 폭력, 이


동 약자)이 포함된 약 1분 길이(3 fps)의 영상 6,492개로 이루어져 있다.



<그림5 이미지 데이터 예시>¹³

본 프로젝트에서는 폭력 감지를 목적으로 하여 6,492개 데이터 중에서 802건의 폭력 데이터만을 이용하였다.

데이터 학습을 위해 moviepy 라이브러리를 이용해 폭력 데이터를 폭력이 일어나는 구간과 폭력이 일어나지 않는 구간으로 분할하였다. 해당 전처리 과정을 거쳐 10초 길이의 폭력 영상 802건, 비폭력 영상 802건이 생성되었고 분석 장비의 한계로 폭력 영상 200건, 비폭력 영상 200건만 활용하였다.



<그림6. 데이터 분할 과정>

¹⁰ Greff, K., Srivastava, R. K., Koutnik, J., Steunebrink, B. R., & Schmidhuber, J. (2016). LSTM: A search space odyssey. IEEE transactions on neural networks and learning systems, 28(10), 2222-2232.

¹¹ 류경근, 최용철, & 이덕규. (2020). GRU 를 활용한 악성코드 탐지의 관한 연구. 한국정보처리학회 학술대회논문집, 27(1), 254-257.

¹² 이재진, 홍현지, 송재민, & 염은섭. (2021). Gated recurrent unit (GRU) 신경망을 이용한 적혈구 침강속도 예측. 한국가시화정보학회지, 19(1), 57-61.

¹³ 실내(편의점, 매장) 사람 이상행동 데이터, AI-Hub

폭력 영상은 1, 비폭력 영상은 0으로 라벨링했다. 각 영상은 30프레임으로 구성되어 있으며, 프레임 별로 분할 후 640 X 640 크기로 resize하여 분석에 이용한다.

각 프레임에서 YOLOv5를 통해 바운딩 박스를 영역으로 설정하여 객체 탐지를 한다. 이후 각 바운딩 박스 안에서 MediaPipe를 통해 사람 관절의 x, y좌표를 추출했다.




<그림7. 관절 좌표 추출 이미지 예시>

데이터 증강기법인 Flipping¹⁴을 통해 데이터를 2배로 늘려 데이터셋의 다양성을 확보하고 과적합을 방지하였다.

해당 과정으로 처리한 데이터를 80%, 10%, 10%의 비율로 Train set(640건), Validation set(80건), Test set(80건)으로 무작위 분할하였다.

III-2. 모델 학습



<그림8. 제안 모델 구조>

본 프로젝트에서는 7개의 RNN layer와 이진 분류를 위한 Dense layer로 GRU 모델을 설계하였다. Input size가 58^{15} 이므로 첫번째 layer의 유닛 수를 64개로 설정했다. 초기 layer에서 다량의 정보를 추출하고 뒤로 갈수록 중요한 특징만 남기도록 layer의 유닛 수를 64, 128, 256, 128, 64, 32, 16으로 구성했다. 또한 과적합 방지를 위해 3번째, 6번째 layer 이후에 dropout 비율이 0.2인 Dropout layer를 각각 추가했다. Dense layer은 마지막 layer의 출력 값을 입력으로 받아 선형 변환을 수행 후 최종 클래스를 0, 1로 반환하였다(그림 8).

손실 함수로는 Cross-Entropy, Optimizer는 Adam으로 설정하였다.

III-3. 분석 결과 및 해석

Precision(수식 1)은 모델이 폭력이라고 탐지했을 때, 실제 폭력인지를 나타내는 지표이다. Recall(수식 2)은 모든 폭력 영상 중에서 폭력을 정확하게 탐지한 지표이다. F1 Score(수식 3)은 Precision과 Recall이

¹⁴ Flipping: 이미지 데이터를 수평 · 수직으로 뒤집어 데이터를 늘리는 기법

¹⁵ 관절 좌표 수: 관절 수 X 2(x, y좌표)

모두 높을 때 큰 값을 가지며, 두 값 간의 균형을 평가하는 지표이다.

제안한 모델은 폭력 행위를 감지하는 모델이므로 실제 폭력 상황에 대한 Recall이 중요하다고 볼 수 있다.

$$Precision = \frac{TP}{TP+FP} \quad (\text{수식 1})$$

$$Recall = \frac{TP}{TP+FN} \quad (\text{수식 2})$$

$$F = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (\text{수식 3})$$

전처리한 데이터를 Epoch 300, Batch Size 8로 설정한 모델에 학습시켰다. 또한 patience 50으로 Early Stopping하도록 설정하여 과적합을 방지하였다.

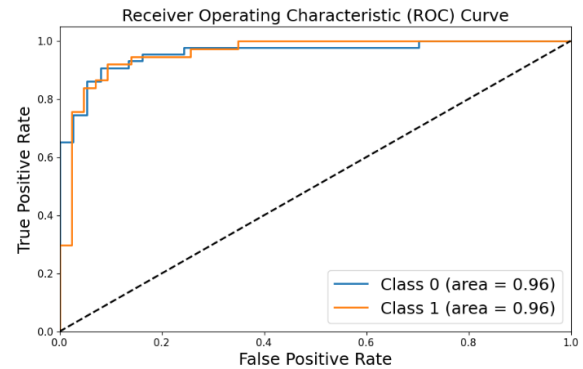
Train accuracy는 88%, Train loss는 0.29 이고, Validation accuracy는 79%, Validation loss는 0.54이다.

모델의 성능을 평가한 결과, test accuracy는 84%이고 폭력 상황에 대한 Recall 값이 0.9로 높게 나온 것을 확인했다(표 1).

<표1 모델 성능 지표(Precision, Recall, F1-score)>

	Precision	Recall	F1 score
비폭력	0.88	0.76	0.82
폭력	0.81	0.9	0.85

분류모델의 전반적인 성능을 평가하는 지표로서 ROC curve를 시각화 하여 확인한 결과, ROC의 면적을 의미하는 AUC 값이 0.96으로 좋은 성능임을 확인하였다(그림 8).



<그림8. 제안한 LSTM 모델의 ROC Curve>

(그림 9)는 AI-Hub CCTV 영상을 활용하여 모델을 테스트한 결과이다.



<그림9. Model 테스트 결과>

III-4. 다른 모델과의 성능 비교

시계열 데이터를 처리하는 또 다른 딥러닝 기법에는 LSTM과 Bidirectional LSTM이 있다. LSTM은 입력 시퀀스를 시간 순서대로 한 방향으로만 처리하는 반면, Bidirectional LSTM은 두 개의 LSTM을 사용하여 입력 시퀀스를 순방향(forward)과 역방향(backward)으로 처리한다.

본 프로젝트에서 제안한 GRU 모델과 동일한 hyperparameter로 LSTM과 Bidirectional LSTM를 비교하였다. (표 2)는

각 모델의 성능테스트를 10번 진행한 결과의 평균값이다.

<표2 모델간 성능 비교표>

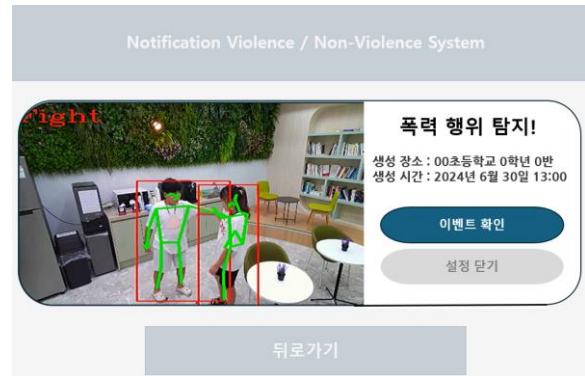
total	Accuracy	Precision	Recall	F1 score
LSTM	0.79975	0.824	0.772	0.795
Bidirectional LSTM	0.77375	0.821	0.733	0.757
GRU	0.805	0.819	0.819	0.806

IV. 활용 방안 및 기대 효과

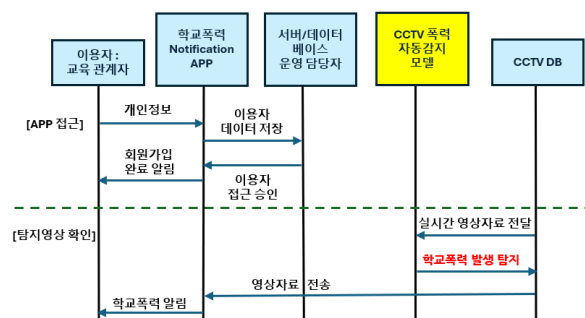
IV-1. 활용 방안

본 프로젝트는 CCTV 데이터를 활용하여 폭력 탐지 모델을 제안하였다. 현재 교내 CCTV는 실시간 탐지 기능의 부재와 통합 관제센터의 인력 부족으로 학교폭력의 실시간 대처가 불가능하여 단순 사후 증거 수집 및 확인용으로만 이용된다.

따라서 본 프로젝트에서 제안한 GRU 기반 폭력 탐지 모델을 학교 CCTV에 적용하고자 한다. 교내 폭력 행위를 실시간 탐지하여 관계자들에게 즉각적인 알리를 제공하여 학교폭력에 발 빠르게 대처할 수 있고 관제 센터 관리 인력 부족 문제를 해결할 수 있다. 활용 예시로 학교폭력 알림 시스템의 User Interface와 도식화된 Sequence Diagram을 (그림 10), (그림 11)로 제시한다.



<그림10. User Interface 예시>



<그림11. Sequence Diagram>

IV-2. 기대 효과

교육부가 발표한 학교폭력 실태조사에 따르면, 교실 안 학교폭력 비율이 37.5%이고 복도, 계단, 운동장, 강당 등의 장소가 31.3%를 차지한다.

CCTV에 실시간 탐지 모델을 적용한다면 학교폭력 적발률을 상승시키고 적발 이후 조치 및 교내폭력 관리체계 개선·개발에 방향을 제시할 수 있다. 나아가 학교폭력만이 아닌, 준·정부 기관, 사기업, 변화가, 도로변 등 사회 내 모든 CCTV에 실시간 탐지 모델을 적용하여 전반적인 사회 시스템 내 폭력 탐지 및 해결에 도움을 줄

수 있다.

또한 폭력 종류, 발생 시간, 장소 등의 데이터 수집 및 분석을 통하여 폭력 발생 위험 지역과 시간대를 도출하고 이에 대한 경비 강화 등 예방 조치를 취할 수 있다.

추가적으로 폭력 외 다른 범죄(청소년 흡연, 방화, 파손, 절도 등) 영상 데이터를 활용한다면 다른 사회 문제를 해결하는 모델로 확장할 수 있다.

(그림 12)는 실시간 폭력 탐지 모델에 대한 Business Model Canvas이다.

Key Partnerships 핵심 파트너	Key Activities 핵심 활동	Value Propositions 가치 제안	Customer Relationships 고객 관계	Customer Segments 고객 세분화
<ul style="list-style-type: none">모형 - 플랫폼 개발 지원 정부기관대용량 영상 데이터 저장 클라우드 기업고성능 CCTV 영상 기술 제공업체AI Solution 제공업체머신러닝 서비스 / UI 개발 업체	<ul style="list-style-type: none">실시간 CCTV DB 분석을 통한 학교폭력 탐지 - 알림실시간 학교폭력 알림 학교폭력 확인 플랫폼Key Resources 핵심 자원국내 가장가는 CCTVYOLOv5 - MediaPipe - LSTM 기반 학교폭력 탐지 플랫폼실시간 학교폭력 감지 알림 시스템	<ul style="list-style-type: none">AI 모델 기반으로 학교폭력 자동 감지학교폭력 초기 발견 및 실시간 조치학교폭력 영상분석 시간 최소화효율적 모니터링학교폭력 적발률 상승	<ul style="list-style-type: none">국내 학교 상담센터교육 관련 분야 서비스 시스템 사용자사용자 커뮤니티Channels 채널모바일 어플리케이션App 연계 WebsiteAI Solution 제공하는 기술 개발 기관	<ul style="list-style-type: none">학교 폭력으로부터 안전한 환경을 요구하는 학부모학교 폭력 자동화 탐지 시스템을 원하는 교육 관계자악목 진압 조차관
Cost Structure 비용 구조 <ul style="list-style-type: none">학교폭력 Application 구축 - 유지보수 비용Server / DB 운영 담당자 고용 급여CCTV DB 저장 - 자동감지 모델 개발 비용		Revenue Streams 수익 구조 <ul style="list-style-type: none">학교폭력 자동탐지 - 예방 솔루션 제공폭력 자동감지 모델 준정부 - 사교육기관 수출학교폭력 Application 원고수익		

<그림12. Business Model Canvas>

V. 참고문헌 및 활용 데이터

통계청, '한국의사회동향', 2023, [온라인] URL: <https://sri.kostat.go.kr/menu.es?mid=a90104010100>, [방문일자:2024-06-19]

한국대학교육협의회, '2024년 4월 대학정보공시 분석 결과 발표', 2024-04-30, [온라인] URL: <https://www.kcue.or.kr/news/sub02/sub01.php?at=view&idx=24154>, [방문일자:2024-06-20]

서울특별시교육청, '2024년도 서울특별시교육비특별회계 예산편성 기본지침', 2023-12-08,

[온라인] URL:

https://buseo.sen.go.kr/buseo/bu05/user/bbs/B_D_selectBbs.do?q_rowPerPage=10&q_currPage=1&q_sortName=&q_sortOrder=&q_searchKeyTy2=1005&q_searchStartDt=&q_searchEndDt=&q_bbsSn=1200&q_bbsDocNo=20231208154725629&q_searchKeyTy=ttl_1002&q_searchVal=&, [방문일자: 2024-06-22]

고은지, "서울 CCTV 관제센터 1인당 평균 958대 담당...적정수준 19배", 연합뉴스, 2022-11-09, URL:

<https://www.yna.co.kr/view/AKR20221109119900004>, [방문일자:2024-06-22] 류경근, 최용철, & 이덕규. (2020).

GRU를 활용한 악성코드 탐지의 관한 연구. 한국정보처리학회 학술대회논문집, 27(1), 254-257.

이재진, 홍현지, 송재민, & 염은섭. (2021). Gated recurrent unit (GRU) 신경망을 이용한 적혈구 침강속도 예측. 한국가시화정보학회지, 19(1), 57-61

교육부, '2023년 1차 학교폭력 실태조사 결과 발표', 2023-12-14, [온라인] URL:

<https://www.moe.go.kr/boardCnts/viewRenew.do?boardID=294&lev=0&statusYN=W&s=moe&m=020402&opType=N&boardSeq=97458>

[방문일자: 2024-06-29]

심태웅, 김도윤, 최종인, & 박광영. YOLOv5 기반의 폐기물 자동인식 시스템 설계

Kwon, Y., & Kim, D. (2022). Real-Time workout posture correction using OpenCV and MediaPipe. 한국정보기술학회논문지, 20(1), 199-208

Chen, K. Y., Shin, J., Hasan, M. A. M., Liaw, J. J., Yuichi, O., & Tomioka, Y. (2022). Fitness

movement types and completeness detection using a transfer-learning-based deep neural network. *Sensors*, 22(15), 5700.

Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2016). LSTM: A search space odyssey. *IEEE transactions on neural networks and learning systems*, 28(10), 2222-2232.

정성우, 김은철, & 유준혁. (2021). CAPS: CCTV 영상을 이용한 자율형 딥러닝 기반 아동학대 감지 시스템. *제어로봇시스템학회 논문지*, 27(12), 1029-1037

박성우, 정승민, 문재욱, & 황인준. (2022). BiLSTM 기반의 설명 가능한 태양광 발전량 예측 기법. *정보처리학회논문지. 소프트웨어 및 데이터 공학*, 11(8), 339-346

주일택, & 최승호. (2018). 양방향 LSTM 순환신경망 기반 주가예측모델. *한국정보전자통신기술학회 논문지*, 11(2), 204-208

AI-Hub 실내(편의점, 매장) 사람 이상행동 데이터
<https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=data&dataSetSn=71550>

서울시 학교 총괄 통계, 통계청
<https://data.seoul.go.kr/dataList/199/S/2/datasetView.do#>

2023학년도 유·초·중·고·특수·각종학교 학급편성 결과. 서울시 교육청
<https://enews.sen.go.kr/news/view.do?bbsSn=183875&step1=3&step2=1>

CCTV 설치 현황, 서울시 교육청

https://buseo.sen.go.kr/buseo/bu15/user/bbs/B_D_selectBbs.do?q_bbsSn=1333&q_bbsDocNo=20220927174206000

제4차 학교폭력 예방 및 대책 5개년 기본계획, 교육부
<https://www.moe.go.kr/boardCnts/viewRenew.do?boardID=316&lev=0&statusYN=W&s=moe&m=0302&opType=N&boardSeq=83086>